

智能垃圾分类系统

基于深度学习的图像分类技术报告

同济大学 Python 程序设计课程小组课题

摘要

本报告针对生活垃圾自动分类问题，基于深度学习技术构建了一套完整的图像分类系统。项目从数据采集与清洗、数据增强、模型架构设计、训练策略优化到模型评估与部署，实现了全流程覆盖。系统支持纸板（**Cardboard**）、玻璃（**Glass**）、金属（**Metal**）、纸张（**Paper**）、塑料（**Plastic**）和其他垃圾（**Trash**）六类物品的自动识别。通过数据集大规模扩充（从 2,497 张扩展至 10,518 张，增幅 321%）和多种先进训练优化技术的综合运用，最终 ConvNeXt Small 模型在独立测试集上达到了 97.48% 的分类准确率，Macro-F1 为 0.9723。实验结果表明，数据规模和质量对分类性能具有决定性影响，结合 Focal Loss、Cosine Warmup 学习率调度、随机权重平均（SWA）和指数移动平均（EMA）等技巧能够有效提升模型泛化能力。项目采用模块化设计，提供了完整的命令行工具链和交互式 Web 演示界面。

关键词：垃圾分类；深度学习；图像分类；卷积神经网络；迁移学习；数据增强

1 引言

随着城市化进程的加速和人口持续增长，生活垃圾产量不断攀升。据统计，全球每年产生超过 20 亿吨城市固体废物，其中约 33% 未得到环境友好型处理。垃圾分类作为资源回收利用和减少环境污染的关键环节，其重要性日益凸显。传统的垃圾分类主要依赖人工分拣，不仅效率低下、成本高昂，而且长期暴露于恶劣环境对工人健康构成严重威胁。近年来，深度学习技术在计算机视觉领域取得了突破性进展，为自动化、智能化的垃圾分类提供了可行的技术路径。

基于深度学习的图像分类方法已经广泛应用于垃圾分类任务中。常用的模型架构包括 VGG、ResNet、MobileNet、EfficientNet 和 ConvNeXt 等。然而，现有研究仍面临两大核心挑战：一是高质量标注数据获取困难，模型性能受限于数据规模和标注质量；二是不同类别的垃圾在视觉特征上存在相似性（如纸板与纸张、透明玻璃与塑料），增加了细粒度分类的难度。此外，实际应用场景中的光照变化、拍摄角度差异和背景干扰等因素也对模型的鲁棒性提出了

更高的要求。因此，在有限标注数据条件下，如何通过数据扩充、迁移学习和训练优化策略来提升垃圾分类模型的性能，是一个具有重要研究价值和实际意义的问题。

本项目旨在设计并实现一个高精度的智能垃圾分类系统。主要目标包括：（1）构建大规模、高质量的垃圾分类数据集，通过多源数据融合解决类别不平衡问题；（2）系统探索多种深度学习模型架构在垃圾分类任务上的性能表现；（3）深入研究数据增强和训练优化策略对模型性能的影响规律；（4）开发交互式用户界面支持便捷的实际应用。项目源自同济大学 Python 程序设计课程的期末小组课题，采用 PyTorch 深度学习框架实现，训练在 NVIDIA GeForce RTX 5060 Laptop GPU 上进行。项目历经八个版本迭代（v1.0.0 至 v1.07），ConvNeXt Small 模型最终达到了 97.48% 的测试准确率。

2 数据描述

2.1 数据来源

项目数据集来自三个不同来源，通过多源数据融合提升了数据规模和多样性。初始数据集为 Kaggle 平台的 Garbage Classification 数据集（TrashNet 数据集的 Kaggle 整理版），包含 2,497 张六类垃圾图像，涵盖纸板、玻璃、金属、纸张、塑料和其他垃圾六类。该数据集图像质量较高，但总量偏少，尤其 trash 类别仅有 136 张图像，导致模型在该类别上性能较差。

为突破数据瓶颈，项目在 v1.06 阶段进行了大规模数据扩充。扩充数据来自两个 Hugging Face 数据源：omasteam/waste-garbage-management-dataset（MIT 许可证，19,762 张图像，10 个类别）和 shahzaibvohra/realwaste（CC BY 4.0 许可证，4,752 张图像，9 个类别）。扩充脚本采用 git sparse clone 技术，只下载所需类别目录，并通过 MD5 哈希去重避免与现有数据重复。所有图像统一缩放至 224×224 像素，以 JPEG 格式（quality=95）保存。通过类别映射，将 realwaste 数据集中非标准类别（如 Textile Trash、Food Organics、Vegetation）归入 trash 类，丰富了其他垃圾的视觉多样性。

2.2 数据集统计

表 1 展示了扩充前后各类别的样本数量分布情况：

类别	扩充前	扩充后	增幅	测试集样本
Cardboard	403	1,825	+353%	365
Glass	500	3,064	+513%	613
Metal	402	1,019	+153%	204

类别	扩充前	扩充后	增幅	测试集样本
Paper	581	1,680	+189%	336
Plastic	475	1,982	+317%	396
Trash	136	948	+597%	190
总计	2,497	10,518	+321%	2,104

表 1 数据集扩充前后各类别样本数量对比。trash 类从 136 张扩充至 948 张（增长 6 倍），大幅缓解了类别不平衡问题。glass 类增幅最大（+513%），成为样本最多的类别。metal 类增幅最小（+153%），仍是样本相对较少的类别。

数据标注包含六类生活垃圾。其中 Cardboard（纸板）包括纸箱、纸板盒等；Glass（玻璃）包括玻璃瓶、玻璃杯等；Metal（金属）包括易拉罐、金属罐等；Paper（纸张）包括报纸、打印纸等；Plastic（塑料）包括塑料瓶、塑料袋等；Trash（其他垃圾）包括脏纸巾、陶瓷碎片等不可回收物。所有标注均经过人工审核确保准确性。

数据集采用分层采样策略进行划分：训练集占 70%（约 7,363 张）、验证集占 10%（约 1,051 张）、测试集占 20%（约 2,104 张）。分层采样确保每个类别在三个子集中保持相同的比例分布。使用两阶段划分方法：先分离测试集（20%），再从剩余数据中分离验证集（占全部数据的 10%），确保测试集完全不参与任何训练决策，保证了评估结果的公正性。

2.3 数据预处理与增强

数据预处理包括数据清洗、去重和标准化三个步骤。数据清洗通过 `Image.open().verify()` 检测并移除损坏的图像文件。去重采用感知哈希（pHash）算法：将图像转换为 8×8 灰度图，计算所有像素的均值，每个像素与均值比较生成 64 位二进制哈希值，通过汉明距离检测内容重复的图像。所有图像统一缩放至 224×224 像素，并按 ImageNet 数据集的均值[0.485, 0.456, 0.406]和标准差[0.229, 0.224, 0.225]进行归一化处理。

为提升模型泛化能力和鲁棒性，训练阶段采用了多层次、组合式的数据增强策略。基础几何增强包括随机水平翻转（50%概率）、随机垂直翻转（30%概率）、随机旋转（±30°）、色彩抖动（亮度、对比度、饱和度各 0.2，色调 0.1）和随机透视变换（畸变尺度 0.1，30%概率）。此外，项目引入了 RandAugment 自动增强策略（随机选取 2 种增强操作，强度 9 级）、CutMix 区域混合增强（Beta 分布参数 $\alpha=0.4$ ，50%概率应用）和 RandomErasing 随机擦除（25%概率，擦除面积占图像 2%-40%）。这些增强策略的组合使用使得模型在有限训练数据下能够学习到更加丰富和鲁棒的特征表示。

3 方法与模型

3.1 模型架构

项目实现了 10 种不同规模的深度学习模型，覆盖了从轻量级自定义卷积神经网络到大规模预训练模型的完整谱系，在参数量上从 1.2M 到 53M 跨越了近两个数量级。这种多层次模型设计使得项目能够在不同应用场景下做出灵活的权衡选择。

SimpleCNN（1.2M 参数）是四层卷积的自定义基线网络，包含 4 个 Conv-BN-ReLU-MaxPool 模块，后接两个全连接层，适合作为性能下限的参考。MobileNetV2（3.5M 参数）采用深度可分离卷积（Depthwise Separable Convolution）将标准卷积分解为逐通道卷积和逐点卷积，参数量减少约 8-9 倍，同时采用倒残差结构（Inverted Residual）实现高效特征提取。ResNet18（11.2M 参数）和 ResNet50（25.6M 参数）利用残差连接（Residual Connection）让梯度可以直接通过跳连接反向传播到浅层，有效缓解了深层网络中的梯度消失问题。

EfficientNetV2-S（21M 参数）和 EfficientNetV2-M（53M 参数）是项目的中坚力量。EfficientNetV2 系列采用 Fused-MBConv 模块，将 MBConv 中的 1×1 升维卷积和 3×3 深度卷积合并为单个 3×3 普通卷积，提高了计算效率。V2-S 在速度和精度之间取得了最佳平衡，是项目中的"甜点"模型。ConvNeXt Tiny（28M 参数）和 ConvNeXt Small（50M 参数）是项目的最先进模型，融合了 Transformer 的设计理念，使用 LayerNorm 替代 BatchNorm、GELU 激活函数和 7×7 大卷积核，同时保持了纯 CNN 架构的推理效率。所有预训练模型均在 ImageNet 上预训练后通过替换分类头迁移至垃圾分类任务。

3.2 损失函数

项目采用 FocalLossWithLabelSmoothing 作为核心损失函数。标准交叉熵损失在处理类别不平衡数据时存在明显缺陷：多数类的梯度信号占据主导，少数类难以得到充分训练。Focal Loss 通过引入调制因子 $(1-pt)^\gamma$ （ $\gamma=2.0$ ）解决了这一问题——当样本 pt 接近 1（易分类）时调制因子接近 0，损失权重被大幅降低；当 pt 接近 0（难分类）时调制因子接近 1，损失权重基本不变。通俗地讲，Focal Loss 告诉模型"不要总盯着你已经会的简单样本，多去关注那些做错的难题"。

标签平滑（Label Smoothing, $\epsilon=0.1$ ）将硬标签转换为软标签分布，使非目标类别获得 2% 的软概率。这种机制防止模型产生过度自信的极端概率输出，提高了泛化能力。项目将 Focal Loss 和 Label Smoothing 两种技术合并为 FocalLossWithLabelSmoothing，同时发挥两者优势：聚焦难分类样本的同时防止过拟合。此外项目还采用了类别权重机制，基于逆类别频率计

算权重（ $\text{weight} = \text{total_samples} / (\text{n_classes} \times \text{class_counts})$ ），使样本数越少的类别在损失计算中被赋予更高的惩罚权重。

3.3 训练策略

项目采用了多阶段、复合式的训练优化方案。学习率调度使用 Cosine Warmup + CosineAnnealingLR：前 5 个 epoch 进行线性预热，学习率从初始值的线性增长到 100%，随后按照余弦函数单调退火至最小值 $1\text{e-}6$ 。预热阶段防止了训练初期的大幅度参数震荡，余弦退火阶段则实现了平滑的学习率衰减。优化器的选择根据模型架构进行差异化配置：EfficientNetV2 系列和 ResNet 系列使用 SGD Nesterov 动量优化器（学习率 0.01，动量 0.9，权重衰减 $1\text{e-}4$ ，梯度裁剪 $\text{max_norm}=1.0$ ），而 ConvNeXt 系列使用 AdamW 优化器（学习率 $1\text{e-}4$ ，权重衰减 0.05，梯度裁剪 $\text{max_norm}=5.0$ ）。

项目还集成了多项高级训练技巧。指数移动平均（EMA，衰减系数 0.999）在训练过程中维护权重的平滑版本——每次权重更新后执行 $\text{new_avg} = 0.999 \times \text{shadow_avg} + 0.001 \times \text{current_weight}$ ，最终得到的平滑权重通常比任何一个时间点的权重都更稳定。随机权重平均（SWA）在最后 25% 的 epoch 中以固定学习率启动，对权重进行等权平均，理论上能找到更宽的最优区域，有利于泛化。项目使用早停机制（ $\text{patience}=30$ 个 epoch）防止过拟合，梯度裁剪防止梯度爆炸，并通过类别平衡采样（WeightedRandomSampler）确保每个 batch 中包含足够多的少数类样本。

3.4 测试时增强与模型集成

测试时增强（Test-Time Augmentation, TTA）在推理阶段发挥作用：对每张测试图像生成 8 个增强版本（原图、水平翻转、4 个旋转角度 $0^\circ/90^\circ/180^\circ/270^\circ$ 、以及翻转后的旋转），取所有版本预测概率的平均值作为最终结果。TTA 能带来 1-2% 的准确率提升，但代价是推理时间增加约 8 倍。模型集成通过对多个独立训练模型的预测概率进行加权平均来取长补短，不同模型可能擅长识别不同类别的垃圾，集成可以有效降低预测方差。

4 实验结果

4.1 整体性能对比

表 2 展示了各模型在扩充后数据集（10,518 张）上的测试性能对比。所有结果均基于独立测试集（2,104 张）得到：

模型	参数量	测试准确率	Macro-F1	推理时间
SimpleCNN	1.2M	51.80%	0.5179	24ms
MobileNetV2	3.5M	82.00%	0.8042	16ms
ResNet18	11.2M	78.00%	0.7632	15ms
EfficientNetV2-S	~21M	96.53%	0.9633	73ms
EfficientNetV2-M	~53M	96.96%	0.9664	4,946ms
ConvNeXt Small	~50M	97.48%	0.9723	2,817ms

表 2 各模型在测试集上的性能对比（所有结果均基于扩充后的 10,518 张数据集）。ConvNeXt Small 以 97.48% 的测试准确率和 0.9723 的 Macro-F1 成为项目最佳模型。EfficientNetV2-S 在精度与效率之间取得了最佳平衡，仅需 73ms 推理时间即可达到 96.53% 的准确率，非常适合实时应用场景。SimpleCNN 作为从零训练的基线模型仅取得 51.80% 的准确率，说明预训练权重对垃圾分类任务至关重要。

值得注意的是，EfficientNetV2-M 虽然在参数量上是 V2-S 的 2.6 倍（53M vs 21M），但测试准确率仅提升了 0.43%（96.96% vs 96.53%）。这一结果表明，在 10,518 张的数据规模下，模型容量已经不是当前的主要性能瓶颈，进一步提升数据集规模可能是获得更高精度的关键。MobileNetV2 以 3.5M 的轻量级参数取得了 82.00% 的准确率，展示了深度可分离卷积的高效性。

4.2 ConvNeXt Small 各类别详细指标

表 3 展示了最佳模型 ConvNeXt Small 在六类垃圾上的精确率、召回率和 F1-Score:

类别	Precision	Recall	F1-Score	支持样本数
Cardboard	0.976	0.986	0.981	365
Glass	0.985	0.982	0.984	613
Metal	0.940	1.000	0.969	204
Paper	0.979	0.976	0.978	336
Plastic	0.969	0.957	0.963	396
Trash	0.983	0.937	0.960	190

表 3 ConvNeXt Small 模型在六类垃圾上各类别的详细分类指标。Metal 类的召回率达到了完美的 1.000，说明 204 张金属测试样本全部被正确识别，无遗漏。Glass 类的 F1-Score 最高（0.984），分类表现最为稳健。Trash 类的 F1-Score 为 0.960，虽然略低于其他类别，但

相比 v1.03 版本的 0.743 已经取得了质的飞跃。**Plastic** 类的召回率相对较低（0.957），主要原因是塑料制品外观差异巨大（从透明瓶到彩色袋），增加了分类难度。

4.3 消融分析

表 4 系统量化了各项改进措施对模型性能的贡献度：

改进措施	准确率提升	主要受益类别
数据集扩充（+8,021 张）	+6.53%	所有类别，尤其 Trash
WeightedRandomSampler	+1-2%	少数类（Trash, Metal）
FocalLossWithLabelSmoothing	+1-2%	难分类样本
Cosine Warmup + CosineAnnealingLR	+0.5-1%	训练稳定性
SWA + EMA	+0.5-1%	模型泛化
测试时增强（TTA）	+1-2%	所有类别
CutMix + RandomErasing	+0.5-1%	鲁棒性

表 4 各项改进措施对模型准确率的贡献度量化分析。消融分析清晰地表明，数据集扩充是性能提升的最关键因素，其贡献（+6.53%）远超其他任何单一改进措施。这一发现印证了"数据是深度学习的燃料"这一核心理念。**trash** 类的 F1 从 v1.03 的 0.743 提升至 0.955（提升 0.212），原因是多方面的：数据扩充使 **trash** 样本增加至原来的 7 倍（136→948 张），加权采样确保了每个 **batch** 中有足够的 **trash** 样本，**Focal Loss** 则让模型将更多注意力集中在 **trash** 这类难分类样本上。

5 结论与展望

5.1 结论

本项目基于深度学习技术成功构建了一套高精度的智能垃圾分类系统，取得了丰硕的成果。在技术成果方面，构建了包含 10,518 张图像的六类垃圾分类数据集，通过多源数据融合有效缓解了类别不平衡问题；实现了 10 种不同规模的深度学习模型，**ConvNeXt Small** 以 97.48% 的测试准确率和 0.9723 的 **Macro-F1** 成为最佳模型。在工程成果方面，项目采用模块化设计，提供了完整的命令行工具链、交互式 **Streamlit Web** 应用和详细的文档体系，支持从数据清洗到模型推理的全流程操作，为后续研究和部署奠定了坚实的技术基础。

在学术贡献方面，项目系统验证了多项训练优化策略的有效性。消融分析揭示了一个重要

发现：数据规模和质量对分类性能具有决定性影响，数据集扩充贡献了 6.53% 的准确率提升，其效果远超 Focal Loss（1-2%）、SWA+EMA（0.5-1%）等算法优化手段。此外，trash 类的 F1 从 0.743 提升至 0.955 的突破性进展，证明了针对少数类的数据扩充和类别平衡采样策略的有效性。这些发现为资源受限条件下的垃圾分类研究提供了有价值的实践指南。

5.2 展望

未来工作可从以下几个方向展开。第一，模型量化部署：通过 INT8 量化和 TensorRT 推理优化，在移动设备和嵌入式平台上实现实时推理，将模型的精度优势转化为实际应用价值。第二，目标检测扩展：从当前的图像分类任务扩展到目标检测任务，支持图像中多个垃圾目标的同时识别与位置定位，更贴近实际应用场景。第三，细粒度分类：将塑料等大类进一步细分为 PET、PP、PE 等子类别，提供更加精细化的分类建议。第四，增量学习机制：使系统在线上后能够持续收集新数据并在线更新模型，适应实际场景中不断变化的垃圾分布特征，避免模型漂移问题。

参考文献

- [1] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016.
- [2] Sandler M, Howard A, Zhu M, et al. MobileNetV2: Inverted Residuals and Linear Bottlenecks[C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018.
- [3] Tan M, Le Q V. EfficientNetV2: Smaller Models and Faster Training[C]. International Conference on Machine Learning (ICML), 2021.
- [4] Liu Z, Mao H, Wu C Y, et al. A ConvNet for the 2020s[C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2022.
- [5] Lin T Y, Goyal P, Girshick R, et al. Focal Loss for Dense Object Detection[C]. IEEE International Conference on Computer Vision (ICCV), 2017.
- [6] Izmailov P, Podoprikin D, Garipov T, et al. Averaging Weights Leads to Wider Optima and Better Generalization[C]. Conference on Uncertainty in Artificial Intelligence (UAI), 2018.
- [7] Cubuk E D, Zoph B, Shlens J, et al. RandAugment: Practical Automated Data Augmentation with a Reduced Search Space[C]. Advances in Neural Information Processing Systems (NeurIPS), 2020.
- [8] Zhang H, Cisse M, Dauphin Y N, et al. MixUp: Beyond Empirical Risk Minimization[C]. International Conference on Learning Representations (ICLR), 2018.

附录

A. 版本迭代历史

版本	日期	核心改进	最佳准确率
v1.0.0	2024-10-15	基线模型+数据清洗+Streamlit 应用	~80%
v1.01	2026-05-12	ResNet18 分类头增强	~82%
v1.02	2026-05-15	Bug 修复+类别权重+增强增强	~85%
v1.03	2026-05-19	+EfficientNetV2-S/ConvNeXt+Focal Loss	90.00%
v1.04	2026-05-22	+CutMix+RandomErasing+TTA	90.20%
v1.05	2026-05-27	+SE 注意力+EMA+知识蒸馏	~92%
v1.06	2026-05-27	数据集扩充至 10,518 张+SWA	96.53%
v1.07	2026-05-29	ConvNeXt Small 最终调优	97.48%

B. 模型配置参数

模型	优化器	学习率	权重衰减	梯度裁剪
SimpleCNN	Adam	1e-3	1e-4	1.0
MobileNetV2	AdamW	5e-5	1e-4	1.0
ResNet18	SGD Nesterov	0.01	1e-4	1.0
EfficientNetV2-S	SGD Nesterov	0.01	1e-4	1.0
EfficientNetV2-M	SGD Nesterov	0.01	1e-4	1.0
ConvNeXt Tiny	AdamW	1e-4	0.05	5.0
ConvNeXt Small	AdamW	1e-4	0.05	5.0

C. 技术栈与依赖

项目基于 Python 3.8+ 开发，核心技术栈包括：PyTorch 2.0.1（深度学习框架，提供张量计算、自动求导和神经网络 API）、TorchVision 0.15.2（预训练模型与图像变换工具）、NumPy 1.24.3（数值计算基础库）、Pandas 2.0.3（结构化数据分析）、Scikit-learn 1.3.0（评估指标与数据集划分）、Matplotlib 3.7.2 和 Seaborn 0.12.2（数据可视化）、Streamlit 1.28.1（Web 交互界面框架）。训练硬件为 NVIDIA GeForce RTX 5060 Laptop（8GB VRAM），总训练时长约 20 小时。

报告撰写完成于 2026 年 6 月